UNIVERSIDADE DE LISBOA
FACULDADE DE CIÊNCIAS
DEPARTAMENTO DE ESTATÍSTICA E INVESTIGAÇÃO OPERACIONAL



Análise Do Abandono De Instituições Bancárias

Martim Luzio (Nº 62054)
Ricardo Morais (Nº 62802)
Miguel Fonseca (Nº 62102)

Unidade Curricular: Aprendizagem Automática e Prospeção De Dados
Docente: Marília Cristina de Sousa Antunes

2025/2026

Resumo

O presente relatório aborda o problema da previsão de abandono de clientes no setor bancário, um elemento crítico para a eficácia das estratégias de retenção. Utilizando dados relativos a clientes de instituições bancárias, o objetivo consistiu na construção e comparação de dois classificadores de naturezas distintas: um modelo de Regressão Logística e uma Árvore de Classificação.

Após a validação e limpeza dos dados, extraíram-se os conjuntos de treino (1000 observações) e de teste (600 observações). Dado o desequilíbrio dos conjuntos da variável resposta, a avaliação de desempenho rejeitou a exatidão global como métrica primária, priorizando a Sensibilidade e a Área Sob a Curva ROC (AUC).

Os resultados evidenciam a superioridade da Regressão Logística face à Árvore de Classificação. A definição do *threshold* utilizando o Índice de Youden no modelo de regressão logística permitiu atingir uma sensibilidade de 87.40%, confirmando esta metodologia como a mais adequada para o contexto de negócio, por maximizar a identificação preditiva de abandonos efetivos.

Conteúdo

1 Introdução **2**

2 Metodologia **2**

2.1 Pré-processamento e Transformação de Dados 2
2.2 Partição dos Dados 2
2.3 Algoritmos de Classificação 2
2.4 Métricas de Avaliação de Desempenho 3

3 Análise **3**

3.1 Conjunto de Dados de Treino 3
3.2 Análise Exploratória dos dados 3
3.2.1 Análise Exploratória das Variáveis Contínuas 3
3.2.2 Análise Exploratória das Variáveis Categóricas 5
3.3 Conjunto de Dados de Teste 5
3.4 Análise da Regressão Logística 6
3.5 Análise da Árvore de Classificação 6
3.6 Análise Comparativa 7

4 Conclusões e Discussão **8**

1. Introdução

Atualmente, os bancos oferecem uma vasta gama de serviços que vai muito além das atividades bancárias tradicionais. Os clientes procuram cada vez mais soluções que melhor respondam às suas necessidades e, frequentemente, optam por mudar de instituição caso não se sintam satisfeitos.

Neste contexto, torna-se essencial que os bancos analisem regularmente os perfis dos seus clientes, de forma a identificar oportunidades de melhoria e reforçar a sua fidelização. Em particular, é crucial compreender quais as características associadas ao potencial abandono e, idealmente, desenvolver modelos que permitam antecipá-lo, possibilitando a implementação de estratégias eficazes de retenção de clientes.

Este relatório tem como objetivo principal responder a este desafio, construindo e comparando o desempenho de classificadores para a ocorrência de abandono com base num conjunto de dados bancários. O foco incidirá na identificação do modelo que melhor equilibra a precisão preditiva com a utilidade prática, fornecendo suporte adequado à tomada de decisão para a retenção de clientes.

2. Metodologia

Para responder aos objetivos propostos, a abordagem metodológica foi estruturada em quatro fases sequenciais: pré-processamento de dados, partição das amostras, construção dos algoritmos de classificação e definição das métricas de avaliação.

2.1 Pré-processamento e Transformação de Dados

A fase inicial consistiu na importação, validação e limpeza do conjunto de dados originais. Procedeu-se à eliminação das observações com valores omissos (*missing values*), retendo-se exclusivamente os casos completos. As variáveis categóricas foram convertidas para fatores e as contínuas mantidas como numéricas.

Durante a análise exploratória, identificou-se que a variável categórica referente ao número de produtos bancários (*NumProdutos*) apresentava amostras muito reduzidas nas categorias de 3 e 4 produtos (22 e 3 observações, respetivamente). Pelo facto de terem uma dimensão de amostra reduzida e para evitar problemas na estimação dos parâmetros, estas categorias foram agrupadas numa nova classe agregada (designada por "3+"), que substituiu a variável original no processo de modelação.

2.2 Partição dos Dados

Para garantir uma avaliação imparcial da capacidade de generalização dos modelos preditivos, os dados foram particionados em dois subconjuntos independentes: um conjunto de treino ($n = 1000$) e um conjunto de teste ($n = 600$). O conjunto de treino foi utilizado exclusivamente para a estimação dos algoritmos, enquanto o conjunto de teste foi estritamente reservado para a avaliação de desempenho.

Para assegurar a total replicabilidade do procedimento de amostragem aleatória, fixou-se uma semente (*seed*) diferente para cada conjunto.

2.3 Algoritmos de Classificação

Com recurso ao conjunto de treino, foram ajustados dois modelos preditivos, permitindo ver duas abordagens estatísticas diferentes com um algoritmo de *Machine Learning* baseado em particionamento:

- **Regressão Logística:** Modelo no qual se assumiu uma distribuição binomial para a variável resposta, utilizando a função de ligação *logit*. Para o modelo de regressão logística aplicou-se um processo de seleção automática de variáveis (*stepwise* bidirecional). O modelo final foi aquele que minimizou o Critério de Informação de Akaike (AIC).

- **Árvores de Classificação:** Modelo baseado em partições binárias recursivas. As árvores de decisão tendem a sofrer de *overfitting* se crescerem até à sua profundidade máxima. Para contornar este problema, a árvore inicial foi sujeita a um processo de poda por complexidade de custo (*cost-complexity pruning*). O parâmetro de complexidade (CP) selecionado foi aquele que minimizou o erro de validação cruzada (*xerror*).

2.4 Métricas de Avaliação de Desempenho

Devido ao desequilíbrio das classes na variável resposta (variável Abandono), a métrica de Exatidão (*Accuracy*) global revela-se desadequada e enviesada para a classe maioritária. Consequentemente, a avaliação de desempenho no conjunto de teste baseou-se nas seguintes métricas:

- **Sensibilidade e Especificidade:** Avaliam, respetivamente, a capacidade de o modelo identificar corretamente os clientes que abandonam (Verdadeiros Positivos) e a capacidade de não classificar erradamente clientes como abandonos (Verdadeiros Negativos).
- **Área Sob a Curva ROC (AUC):** Mede a capacidade discriminatória global do classificador ao longo de todos os limiares de decisão possíveis.

Complementarmente, a aplicação direta do modelo de regressão logística requer a definição de um ponto de corte (*threshold*). Em vez da utilização de um *threshold* convencional de 0.5, procedeu-se à utilização do Índice de Youden (J), cuja formulação é dada por:

$$J = \text{Sensibilidade} + \text{Especificidade} - 1$$

Deste modo é possível determinar o ponto de corte que maximiza a sensibilidade e especificidade.

3. Análise

3.1 Conjunto de Dados de Treino

O conjunto de treino é composto por 1000 observações, das quais 810 (81.00%) correspondem a clientes que não abandonaram e 190 (19.00%) a clientes que abandonaram.

3.2 Análise Exploratória dos dados

3.2.1 Análise Exploratória das Variáveis Contínuas

Para as variáveis contínuas, foram produzidos *boxplots* por grupo de abandono, representados na Figura 1. Da análise efetuada, a variável **Idade** destaca-se como o preditor numérico com maior poder discriminatório: os clientes que abandonam apresentam uma mediana de idade visivelmente superior à dos que permanecem, sugerindo que clientes mais velhos têm maior propensão ao abandono. Isto ainda que o grupo que não abandona tem vários outliers.

Na variável **Saldo** também se verifica que quem tem valores superiores da mesma está no grupo que abandona. Poderá possivelmente haver uma relação entre os dois.

As variáveis **ScoreCredito**, **Antiguidade** e **SalarioEstimado** revelam distribuições muito semelhantes entre os dois grupos, sugerindo fraca capacidade preditiva. A análise da matriz de correlação (Figura 2) confirma ainda que as variáveis numéricas são praticamente não correlacionadas entre si, não se antecipando problemas de multicolinearidade na estimação dos modelos.

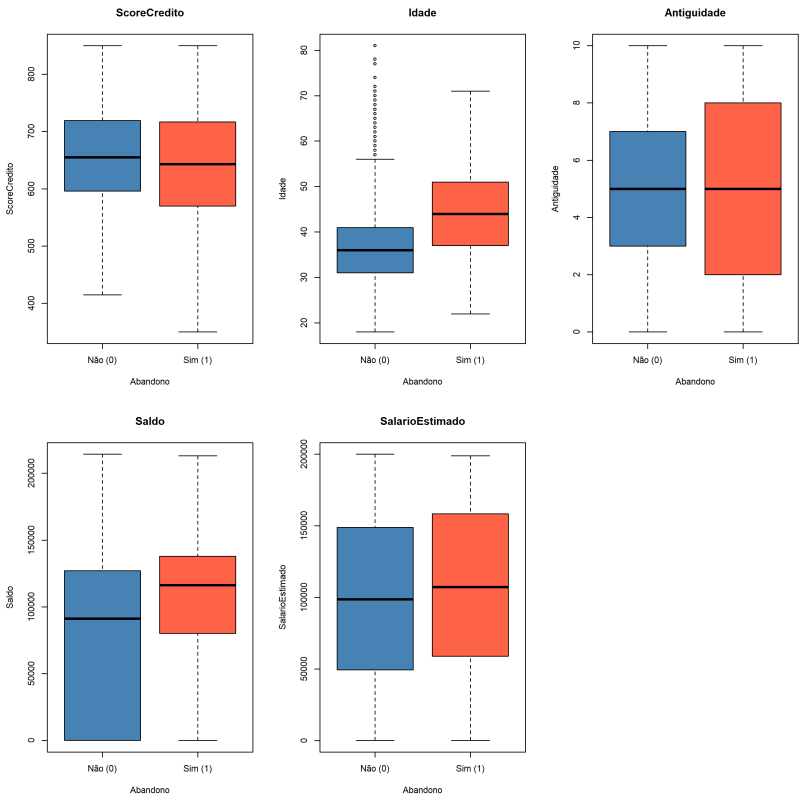


Figura 1: Boxplots das variáveis contínuas por grupo de abandono (conjunto de treino).

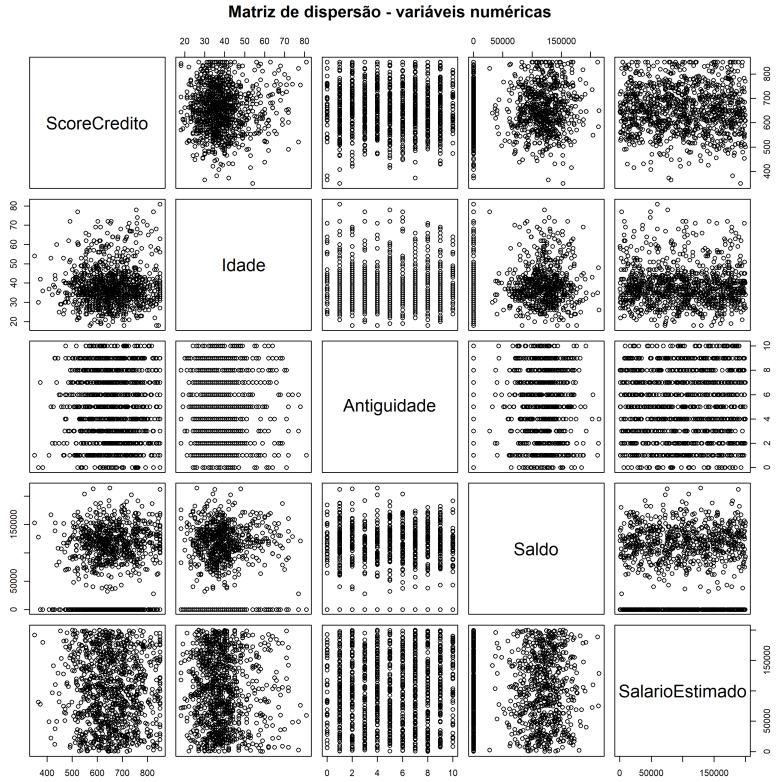


Figura 2: Matriz de dispersão e correlação entre as variáveis numéricas (conjunto de treino).

3.2.2 Análise Exploratória das Variáveis Categóricas

Para as variáveis categóricas, foram calculadas tabelas de proporção de abandono por categoria e produzidos gráficos de barras empilhadas (Figura 3), permitindo identificar quais os grupos com maior propensão ao abandono.

A variável **NumProdutos** apresenta o padrão mais expressivo: os clientes com 2 produtos bancários registam a menor taxa de abandono, enquanto os clientes com apenas 1 produto abandonam em cerca de 28.00% dos casos. As categorias com mais de 3 produtos, apesar de apresentarem taxas de abandono elevadas, contam com amostras muito reduzidas (25 observações), pelo que devem ser interpretadas com cautela.

Relativamente à **Geografia**, os clientes oriundos da Alemanha apresentam uma taxa de abandono superior à dos clientes franceses e espanhóis, sugerindo que a localização geográfica é um fator relevante.

A variável **ClienteAtivo** revela que os clientes não ativos abandonam a instituição com maior frequência do que clientes ativos, que é por sua vez lógico e interpretável. A inatividade pode ser um sinal precursor de abandono.

O **Género** apresenta uma diferença mais pequena, com clientes do sexo feminino a registrar uma taxa de abandono ligeiramente superior à do sexo masculino.

Por fim, a variável **CartaoCred** não evidencia diferenças expressivas entre as categorias, sugerindo que a posse de cartão de crédito tem pouca associação com o abandono.

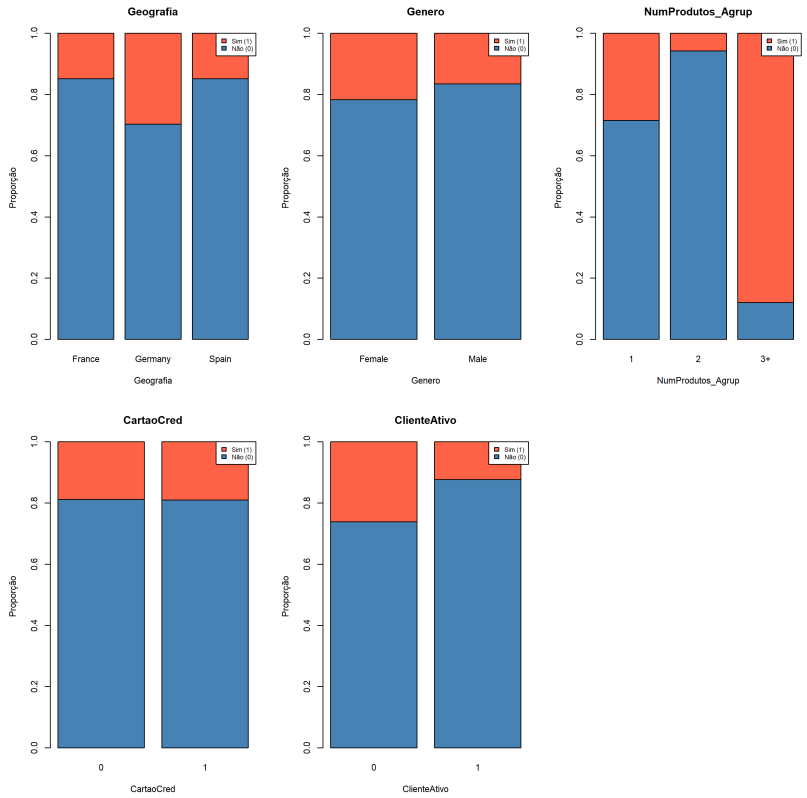


Figura 3: Proporção de abandono por categoria para cada variável categórica (conjunto de treino).

3.3 Conjunto de Dados de Teste

A avaliação dos classificadores foi realizada no conjunto de teste composto por 600 observações, dos quais 473 (78.83%) correspondem a não abandono e 127 (21.17%) a abandono.

3.4 Análise da Regressão Logística

As variáveis retidas pelo algoritmo *step* foram **NumProdutos**, **Idade**, **ClienteAtivo**, **Geografia**, **Genero**, **SalarioEstimado** e **ScoreCredito**. As variáveis **NumProdutos**, **Idade**, **ClienteAtivo**, **Geografia** e **Genero** são as mais significativas. Apesar de as outras não terem significância estatística são relevantes no modelo por conterem informação importante (Critério de AIC).

Para a regressão logística, o *threshold* de classificação foi definido pelo índice de Youden, que maximiza a soma de sensibilidade e especificidade, sendo mais adequado do que o *threshold* convencional de 0.5 num contexto em que detetar abandonos é prioritário.

Com o *threshold* de *Youden* (0.15), o modelo apresenta uma sensibilidade de 87.40%, identificando corretamente 111 dos 127 abandonos. Este é o resultado mais relevante do ponto de vista do negócio.

A especificidade de 64.50% e a *accuracy* de 69.30% são mais baixas, o que reflete o *trade-off* inerente da utilização do índice de *Youden*. O modelo torna-se mais conservador na classificação "não abandona", obtendo mais falsos positivos. O AUC de 0.83 confirma uma boa capacidade discriminatória global. (Figura 4).

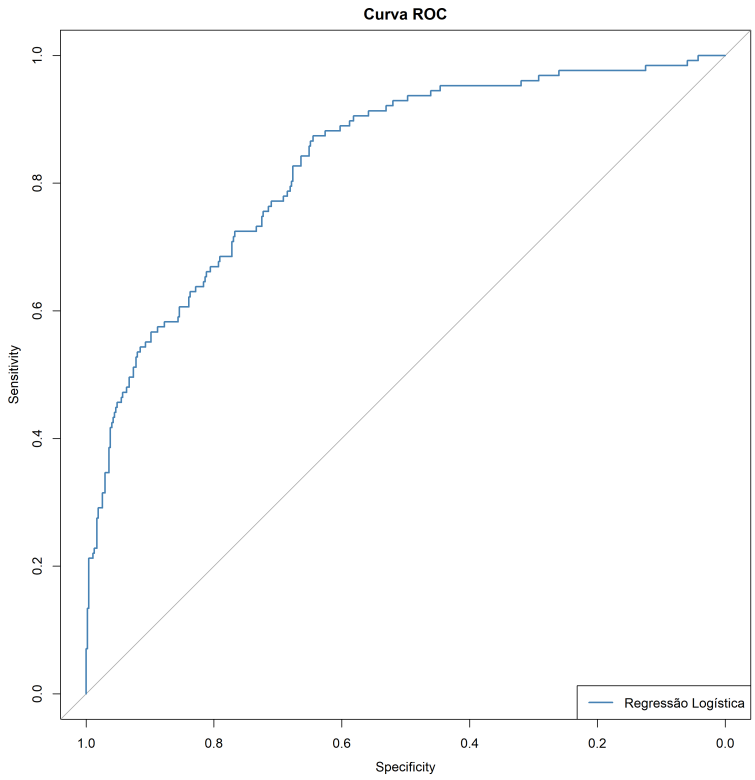


Figura 4: Curva ROC do modelo de Regressão Logística no conjunto de teste ($AUC = 0.83$).

3.5 Análise da Árvore de Classificação

A árvore apresenta uma *accuracy* de 80.80% e uma especificidade elevada (94.10%), mas uma sensibilidade de apenas 31.50% — identifica corretamente apenas 40 dos 127 abandonos.

Este perfil é claramente inadequado para um problema de retention de clientes, onde o objetivo central é precisamente antecipar quem vai abandonar.

O AUC de 0.73 confirma uma capacidade discriminatória global inferior à da regressão logística (Figura 5).

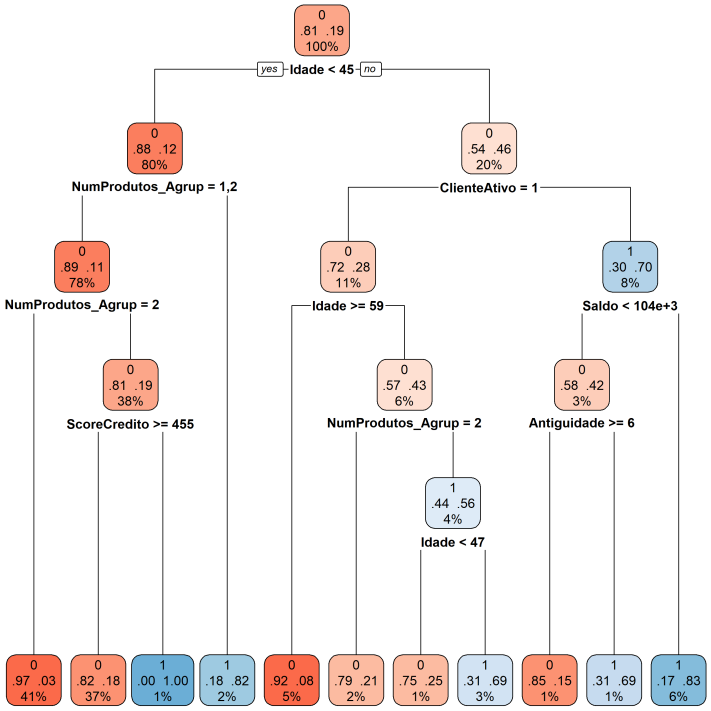


Figura 5: Árvore de Classificação, com as proporções de classe e percentagem de observações em cada nó.

3.6 Análise Comparativa

Os dois modelos apresentam perfis de desempenho opostos. A árvore tem maior *accuracy* e especificidade, mas a regressão logística supera-a em todas as métricas que importam para este problema, sensibilidade e *AUC*. A diferença no *AUC* (0.83 vs 0.73) é a mais expressiva, por ser independente do *threshold* e refletir a capacidade discriminatória global de cada modelo, confirmada visualmente pela curva ROC (Figura 6).

A árvore de classificação, por produzir um número limitado de *thresholds* distintos, tem menor flexibilidade no *trade-off* sensibilidade/especificidade, o que se reflete na sua curva ROC que está mais próxima da linha diagonal. A regressão logística, ao modelar diretamente probabilidades contínuas, permite ajustar esse *trade-off* de melhor forma.

Tabela 1: Comparação do desempenho dos classificadores no conjunto de teste.

Modelo	**Accuracy**	**Sensibilidade**	**Especificidade**	**AUC**
Regressão Logística (Youden)	69.30%	87.40%	64.50%	0.83
Árvore de Classificação	80.80%	31.50%	94.10%	0.73

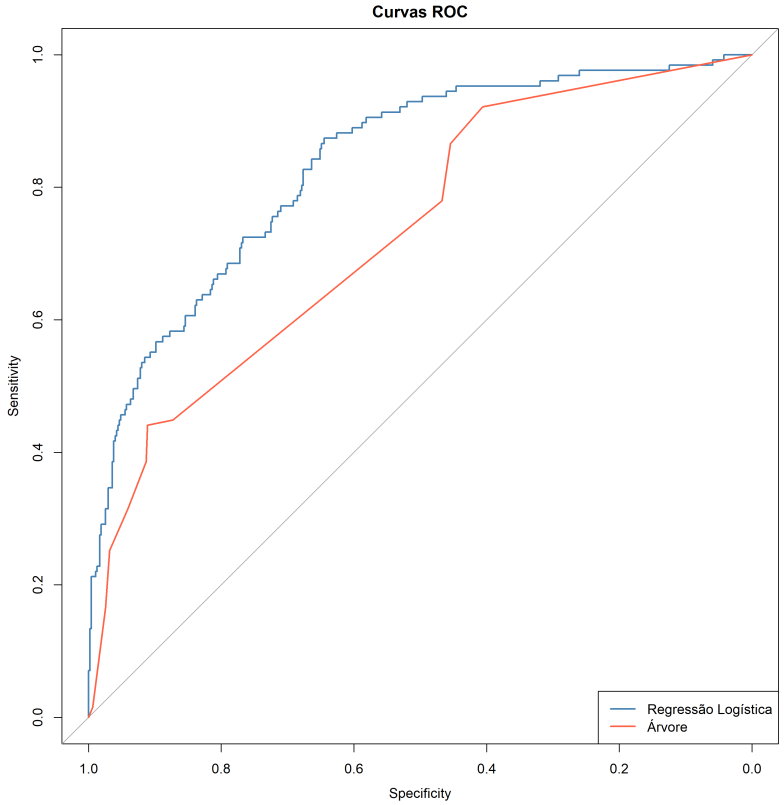


Figura 6: Curvas ROC sobrepostas dos dois classificadores no conjunto de teste

4. Conclusões e Discussão

As variáveis identificadas na análise exploratória como tendo maior poder discriminatório, nomeadamente a **Idade**, o **NumProdutos**, a **Geografia** e o **ClienteAtivo**, foram retidas pelo algoritmo *stepwise*, o que reforça a necessidade de uma boa análise exploratória. A única exceção foi a variável **Saldo**.

A **Regressão Logística** com *threshold* de *Youden* demonstrou ser o classificador mais adequado para o objetivo de retenção de clientes, identificando corretamente 87.40% dos abandonos efetivos. O *trade-off* foi uma especificidade de 64.50%, traduzida num maior número de falsos positivos o que é aceitável no contexto de negócio. Isto porque o custo de não identificar um abandono real tende a ser superior ao custo de implementar desnecessariamente uma estratégia de retenção do cliente.

A **Árvore de Classificação**, apesar da *accuracy* superior (80.80%), revelou-se inadequada para este problema ao identificar corretamente apenas 31.50% dos abandonos. Um classificador que falha em antecipar mais de dois terços dos clientes que abandonam tem utilidade prática muito limitada, independentemente da sua *accuracy*.

Como limitação principal, os modelos foram construídos e avaliados com base numa única partição dos dados, o que pode introduzir variabilidade nos resultados. Em trabalhos futuros, seria pertinente explorar técnicas como o SMOTE e/ou *resampling* para lidar com o desequilíbrio de classes, ou modelos de maior complexidade como *random forests*.

Nota: Foi utilizado o modelo de IA Gemini (Google) como ferramenta de suporte de estudo do projeto.

Bibliografia

[1] R Core Team (2023). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. Disponível em: `https://www.R-project.org/`.

[2] Antunes, M. (2015). *Prospecção de Dados: princípios e métodos – Texto de apoio à disciplina de CRM e prospecção de dados*. Centro de Estatística e Aplicações da Universidade de Lisboa, Lisboa.

[3] Antunes, M. *Árvores de decisão e Classificador bayesiano simples*. Texto de apoio à disciplina de Aprendizagem Automática e Prospeção de Dados, Licenciatura em Estatística Aplicada, Departamento de Ciências Matemáticas, Faculdade de Ciências da Universidade de Lisboa, Lisboa, Slides 0/70–70/70.

[4] Antunes, M. *Construção de classificadores: Abordagem discriminativa, Regressão e Regra de Fisher*. Texto de apoio à disciplina de Aprendizagem Automática e Prospeção de Dados, Licenciatura em Estatística Aplicada, Departamento de Ciências Matemáticas, Faculdade de Ciências da Universidade de Lisboa, Lisboa, Slides 0/37–37/37.

[5] Antunes, M. *Introdução à Modelação Preditiva e Modelos Probabilísticos para Classificação*. Texto de apoio à disciplina de Aprendizagem Automática e Prospeção de Dados, Licenciatura em Estatística Aplicada, Departamento de Ciências Matemáticas, Faculdade de Ciências da Universidade de Lisboa, Lisboa, Slides 0/40–40/40.